

Predicția Adicției față de Smartphone

Proiect - Sisteme Inteligente

Laura Cristina Homorodan

2026

Cuprins

1		3
1.1	Introducere	3
1.2	Motivația alegerii bazei de date	3
1.2.1	Stresul și degradarea somnului	3
1.2.2	Necesitatea Inteligenței Artificiale în analiza adicției	4
2		5
2.1	Contextul sursei de date	5
2.2	Cerințe și etape tehnice	6
2.3	Obiectivele urmărite	6
3		7
3.1	Starea actuală a cercetării (State-of-the-Art)	7
3.2	Fundamentele teoretice ale algoritmilor utilizați	8
3.2.1	Arborii de Decizie și Metrica Gini	8
3.2.2	Random Forest: Puterea Ansamblului	8
3.2.3	Regresia Logistică și Probabilitatea	8
3.2.4	Selecția caracteristicilor prin Mutual Information	8
4		9
4.1	Încărcarea și curățarea datelor	9
4.1.1	Analiza relevanței variabilelor	9
4.1.2	Împărțirea datelor și validarea modelelor	9
4.1.3	Algoritmii aleși și justificarea selecției	10
4.1.4	Optimizarea hiperparametrilor prin Grid Search	10
4.2	Analiza matricei de corelație	10
5		12
5.1	Metrici de evaluare utilizate	12
5.2	Analiza comparativă a algoritmilor	12
5.2.1	Interpretarea rezultatelor	13
5.2.2	Unde greșește modelul?	13
6		14
Rezultate și Discuții		14
6.1	Performanța modelului final	14
6.2	Analiza erorilor	14
6.3	Explicabilitatea modelului	14

7		16
7.1	Cunoștințe extrase din proiect	16
7.2	Limitările abordării	16
7.3	Îmbunătățiri și direcții viitoare	17
7.4	Utilizarea modelului în psihologia comportamentală	17

Capitolul 1

1.1 Introducere

Datasetul utilizat reprezintă o resursă esențială concepută pentru a sprijini cercetătorii și analiștii de date în înțelegerea impactului tot mai mare al smartphone-urilor asupra vieții de zi cu zi și a sănătății mentale. Având în vedere îngrijorările globale legate de adicția digitală și efectele acesteia asupra productivității, somnului și interacțiunilor sociale, acest set de date este un instrument valoros pentru identificarea tendințelor, modelelor comportamentale și a riscurilor potențiale. În cadrul acestui proiect, datele sunt utilizate pentru o analiză comportamentală aprofundată, explorând modul în care utilizarea excesivă a tehnologiei influențează stilul de viață modern.

1.2 Motivația alegerii bazei de date

Decizia de a studia adicția față de smartphone nu a venit doar dintr-un interes față de tehnologie, ci și dintr-o observație: tot mai mulți oameni, tineri și adulți, chiar și copii, raportează dificultăți de concentrare, anxietate la separarea de telefon și un somn tot mai slab, fără să identifice neapărat dispozitivul ca sursă a problemei.

Conform datelor Statista și DataReportal, în 2024 numărul utilizatorilor de smartphone a depășit 4,8 miliarde, adică aproape 60% din populația globului, față de sub 45% în urmă cu un deceniu. Impactul se simte puternic la nivelul proceselor cognitive, unde fenomenul de „atenție fragmentată” reduce capacitatea de învățare profundă, un aspect care este prezent în structura datasetului analizat în acest proiect.

1.2.1 Stresul și degradarea somnului

Stresul și somnul prost nu sunt două efecte separate ale utilizării excesive, ele se alimentează unul pe celălalt, formând un cerc din care e greu de ieșit. Notificările constante mențin creierul într-o stare de alertă continuă. Fiecare semnal sonor sau vizual declanșează o mică eliberare de dopamină, suficientă cât să întrețină obiceiul, dar nu suficientă cât să-l satisfacă. Pe fondul acestei stimulări repetate, nivelul de cortizol crește, iar utilizatorul ajunge să apeleze la telefon tocmai pentru a reduce un stres pe care tot telefonul l-a generat. Noaptea, lumina ecranului perturbă secreția de melatonină, întârziind somnul și reducându-i calitatea. A doua zi, oboseala afectează capacitatea de autocontrol, iar un creier insuficient odihnit cedează mai ușor impulsului de a verifica din nou dispozitivul. Ciclul se reia.

1.2.2 Necesitatea Inteligenței Artificiale în analiza adicției

Adicția față de smartphone nu urmează o logică simplă. Nu se poate spune că „după 5 ore oricine devine dependent”, pentru că profilul fiecărui om este diferit. Un utilizator care stă mult pe telefon pentru muncă (productivitate) este complet diferit de unul care petrece același timp pe rețele sociale sau jocuri, deși numărul de ore afișat este identic.

Tocmai de aceea, o analiză statistică obișnuită nu este de ajuns. Se poate observa că există o legătură între stres și notificări, dar lucrurile devin cu adevărat grave abia când combinăm notificările multe cu un somn de sub șase ore.

Algoritmii de *Machine Learning* sunt făcuți exact pentru acest lucru. Ei nu se uită la un singur factor, ci analizează simultan totul: vârstă, gen, ore de social media, deblocări de ecran și ore de somn. Ei caută acele tipare ascunse. În acest proiect, Machine Learning este folosit nu pentru că e o metodă modernă, ci pentru că este singura capabilă să descifreze cât de complexă este, în realitate, relația omului cu tehnologia.

Capitolul 2

2.1 Contextul sursei de date

Setul de date utilizat provine de pe platforma Kaggle și a fost publicat sub numele *Smartphone Usage and Addiction Analysis Dataset*. Acesta conține înregistrări individuale ale utilizatorilor de smartphone, fiecare rând reprezentând profilul unei persoane distincte.

Datele analizate cuprind atât informații despre utilizatori, cât și detalii despre cum folosesc aceștia telefonul. Tabelul de mai jos prezintă cele două categorii principale:

Tabela 2.1: Clasificarea și descrierea variabilelor din dataset

Categorie	Variabilă	Descriere / Unități
Cantitative	Ore de utilizare zilnică	Timp total de ecran (ore)
	Social Media Hours	Timp alocat rețelelor sociale (ore)
	Gaming / Productivity	Timp alocat jocurilor / utilităților
	Număr de notificări	Volumul zilnic de alerte primite
	Deblocări ecran	Frecvența activării dispozitivului
	Ore de somn	Durata repausului nocturn (ore)
Calitative	Gen (Gender)	Masculin / Feminin / Altul
	Nivel de stres	Autoevaluare pe scară calitativă
	Anxietate digitală	Prezența simptomelor specifice
Target	<code>addicted_label</code>	Clasificare binară (0 sau 1)

Această etapă de clasificare a variabilelor este esențială pentru faza de pre-procesare, asigurând formatul necesar pentru antrenarea algoritmilor:

- **Variabilele numerice (cantitative)** permit observarea unor corelații directe, cum ar fi impactul creșterii nivelului de stres asupra duratei somnului.
- **Variabilele descriptive (calitative)**, precum genul sau prezența anxietății, sunt transformate în valori numerice prin tehnica *Label Encoding*, proces necesar pentru ca modelele să poată efectua calculele matematice aferente.

Variabila țintă a studiului este `addicted_label`. Deși setul de date original clasifica utilizatorii în patru niveluri de severitate (*None*, *Mild*, *Moderate* și *Severe*), s-a ales o grupare binară: valoarea „0” pentru absența riscului și „1” pentru prezența unui grad de adicție. Această simplificare are scopul de a crește precizia modelelor în identificarea distincției fundamentale dintre un comportament normal și unul problematic.

2.2 Cerințe și etape tehnice

Pentru realizarea sistemului de clasificare, procesul a fost structurat în următoarele etape tehnice esențiale:

1. **Curățarea și transformarea datelor:** Această etapă a asigurat trecerea de la date brute la un format ce poate fi prelucrat matematic:
 - **Binarizarea variabilei țintă:** Conversia coloanei *addiction_level* în eticheta numerică *addicted_label*. Aceasta este cerința centrală a proiectului: transformarea celor patru niveluri calitative (*None*, *Mild*, *Moderate*, *Severe*) în clase binare, unde **0** reprezintă absența adicției și **1** prezența oricărui grad de risc.
 - **Encoding:** Utilizarea *LabelEncoder* pentru a transforma variabilele de tip text (precum *Gender*) în valori numerice, deoarece algoritmi nu pot lucra direct cu cuvinte.
 - **Integritate:** Eliminarea duplicatelor și gestionarea valorilor lipsă (prin completarea cu „None”) pentru a evita erorile de calcul în timpul antrenării.
2. **Modelarea predictivă:** Antrenarea și compararea a trei algoritmi (*Random Forest*, *Regresie Logistică*, *Arbore de Decizie*) pentru a vedea care reușește să identifice cel mai bine diferența dintre clasele 0 și 1.
3. **Optimizarea prin GridSearchCV:** Testarea automată a diferiților parametri (hiperparametri) pentru fiecare algoritm în parte, folosind validarea încrucișată pe 3 segmente (*cv=3*), pentru a obține cea mai bună performanță posibilă.
4. **Selecția caracteristicilor:** Analiza variabilelor prin trei metode (*Pearson*, *Mutual Information* și *Gini Index*) pentru a descoperi care comportamente (ex: somnul sau notificările) sunt cei mai buni predictorii pentru clasa 1 (adicție).

2.3 Obiectivele urmărite

Principalul obiectiv al acestei lucrări este dezvoltarea unui instrument capabil să identifice riscul de adicție, oferind în același timp o explicație clară asupra cauzelor care duc la acest lucru. Nu se urmărește doar obținerea unui model matematic precis, ci crearea unui sistem care să arate modul în care diferite obiceiuri digitale interacționează între ele.

Prin prioritizarea analizei factorilor de risc, studiul își propune să răspundă la întrebări esențiale: în ce măsură timpul petrecut pe rețelele sociale este mai dăunător decât utilizarea telefonului pentru jocuri și cum influențează frecvența notificărilor starea generală de stres. Astfel, proiectul urmărește să scoată în evidență „punctele critice” din comportamentul utilizatorului, cum ar fi relația dintre orele de somn pierdute și utilizarea nocturnă a dispozitivului.

În final, utilitatea programului constă în capacitatea sa de a servi drept bază pentru soluții de prevenție. Rezultatele obținute pot fi integrate în aplicații de sănătate digitală care să emită alerte personalizate, ajutând utilizatorul să își corecteze obiceiurile înainte ca dependența să aibă un impact sever asupra calității vieții.

Capitolul 3

3.1 Starea actuală a cercetării (State-of-the-Art)

Studiul adicției de smartphone a evoluat semnificativ în ultimul deceniu, trecând de la simple chestionare auto-raportate la modele complexe de analiză predictivă bazate pe inteligență artificială.

Conform cercetărilor fundamentale realizate de *Kwon et al. (2013)*, a fost stabilită prima scară de măsurare validată, cunoscută sub numele de **Smartphone Addiction Scale (SAS)** [1]. Aceasta a demonstrat că dependența digitală nu este definită doar de timpul petrecut pe dispozitiv, ci de pierderea controlului asupra vieții cotidiene. Ulterior, studii realizate de *Demirci et al. (2015)* au evidențiat o corelație critică între utilizarea smartphone-ului și degradarea sănătății mentale, identificând niveluri crescute de anxietate și depresie în rândul utilizatorilor intensi [2].

Impactul fiziologic a fost analizat de *Christensen et al. (2016)*, care a demonstrat prin date obiective cum utilizarea ecranelor înainte de culcare reduce drastic calitatea somnului prin inhibarea melatoninei [3]. Această observație este susținută și de lucrarea lui *Hale și Guan (2015)*, care subliniază că privarea de somn alimentează un cerc vicios de oboseală și utilizare compulsivă a tehnologiei [4].

Utilizarea algoritmilor de învățare automată reprezintă „frontiera” actuală în domeniu. În timp ce metodele clasice se bazau pe corelații simple, cercetări recente, precum cele ale lui *Samaha și Hawi (2016)*, arată că relația dintre satisfacția de viață și adicția digitală este nelineară, necesitând modele mai avansate de procesare [5].

Modelele de tip **Random Forest**, utilizate și în prezentul proiect, au fost validate în studii precum cel al lui *Gokcearslan et al. (2016)*, care au demonstrat că factori precum auto-reglarea și vârsta sunt predictorii mai puternici decât timpul brut de utilizare [6]. Mai mult, *Lin et al. (2015)* a propus sisteme automate de screening care pot identifica riscul de adicție în timp real prin analiza jurnalelor de utilizare (log-uri), atingând o precizie similară cu evaluările clinice [7].

Două concepte esențiale în starea actuală a domeniului sunt **FOMO** (*Fear of Missing Out*) și **Nomofobia**. *Przybylski et al. (2013)* au definit FOMO ca o forță motrice a utilizării excesive a rețelelor sociale [8], în timp ce *Yildirim și Correia (2015)* au dezvoltat instrumente de măsurare a nomofobiei (anxietatea provocată de absența telefonului), demonstrând că aceasta afectează productivitatea și capacitatea de concentrare [9].

În final, integrarea acestor factori în sisteme inteligente, așa cum propun *Tandon et al. (2020)*, permite tranziția de la simpla monitorizare la intervenția preventivă personalizată [10], direcție pe care se axează și proiectul de față.

3.2 Fundamentele teoretice ale algoritmilor utilizați

Pentru a transforma datele brute în predicții, proiectul se bazează pe trei modele de învățare supervizată, fiecare având un mod diferit de a „gândi”.

3.2.1 Arborii de Decizie și Metrica Gini

Un Arbore de Decizie funcționează printr-o serie de întrebări logice (ex: „Utilizatorul doarme mai puțin de 6 ore?”). În fiecare nod al arborelui, algoritmul caută variabila care separă cel mai bine utilizatorii dependenți de cei non-dependenți.

Pentru a măsura calitatea acestei separări, se folosește **Indicele Gini**. Din punct de vedere teoretic, acesta măsoară „impuritatea” unui grup. Dacă într-un grup toți utilizatorii sunt dependenți, indicele Gini este 0 (puritate maximă). Scopul algoritmului este să scadă acest indice la fiecare pas, alegând variabilele cele mai relevante, cum ar fi orele de social media sau nivelul de stres.

3.2.2 Random Forest: Puterea Ansamblului

Deoarece un singur arbore de decizie poate deveni prea specific (fenomenul de *overfitting*), s-a optat pentru utilizarea modelului **Random Forest**. Acesta este un algoritm de tip „ansamblu” care creează sute de arbori de decizie diferiți, antrenati pe porțiuni aleatorii din date.

Decizia finală a modelului nu aparține unui singur arbore, ci este rezultatul unui vot majoritar. Dacă majoritatea arborilor „votează” că profilul unui utilizator indică adicția, modelul va returna clasa 1. Această metodă oferă o stabilitate mult mai mare și o precizie superioară în fața datelor zgomotoase.

3.2.3 Regresia Logistică și Probabilitatea

Spre deosebire de arbori, **Regresia Logistică** este un model statistic care calculează probabilitatea ca un utilizator să aparțină clasei 1. Algoritmul folosește o funcție matematică numită *funcție sigmoidă*, care transformă orice valoare numerică într-un interval cuprins între 0 și 1.

Dacă rezultatul calculului este, de exemplu, 0.75, modelul consideră că există o probabilitate de 75% ca utilizatorul să fie dependent, clasificându-l automat în categoria 1. Acest model este extrem de util pentru a înțelege direcția relațiilor liniare dintre variabile.

3.2.4 Selecția caracteristicilor prin Mutual Information

În afara modelelor de predicție, un aspect teoretic esențial în proiect este utilizarea **Mutual Information (MI)**. Această metrică măsoară dependența dintre două variabile. Spre deosebire de corelația clasică, MI poate detecta dacă o variabilă este utilă chiar dacă relația ei cu adicția nu este o linie dreaptă, măsurând practic câtă incertitudine elimină acea variabilă din modelul nostru.

Capitolul 4

4.1 Încărcarea și curățarea datelor

Primul pas a constat în încărcarea fișierului CSV folosind biblioteca `pandas`, urmată de o inspecție inițială a structurii datelor: numărul de rânduri, tipurile de coloane și distribuția valorilor. Explorarea a scos la iveală două categorii de probleme: valori lipsă în coloana *addiction_level* și un număr de înregistrări duplicate.

Valorile lipsă au fost completate cu eticheta „None”, fiind că absența unei valori în această coloană indică cel mai probabil un utilizator fără semne de adicție, nu o eroare de colectare. Duplicatele au fost eliminate complet, păstrând doar prima apariție a fiecărei înregistrări. Înainte de antrenare, coloanele care nu reprezintă predictorii comportamentali bruti (*user_id*, *addiction_level* și *addicted_label*) au fost excluse din matricea de intrare. Variabilele categoriale rămase, precum *gender*, au fost transformate numeric prin `LabelEncoder`, asigurând formatul necesar pentru algoritmii de Machine Learning.

4.1.1 Analiza relevanței variabilelor

Înainte de etapa de antrenare, a fost realizată o analiză sistematică a contribuției fiecărui predictor prin trei metode complementare:

- **Corelația Pearson:** A măsurat direcția și intensitatea relației liniare dintre fiecare variabilă și eticheta țintă *addicted_label*.
- **Mutual Information:** A completat această imagine surprinzând și relațiile neliniare, măsurând cât de mult reduce incertitudinea cunoașterea valorii unui predictor.
- **Importanța Gini:** Extrasă dintr-un arbore de decizie cu adâncime trei, aceasta a indicat eficiența fiecărei variabile în separarea claselor.

Aplicarea acestui set de trei metode garantează o selecție echilibrată a datelor, prevenind pierderea unor indicatori esențiali pe care o singură analiză izolată i-ar putea subevalua.

4.1.2 Împărțirea datelor și validarea modelelor

Setul de date a fost împărțit în proporție de 80% pentru antrenare și 20% pentru testare, folosind funcția `train_test_split` cu parametrul `random_state=42` pentru reproductibilitate.

Nu a fost constituit un set de validare separat; în locul acestuia, validarea modelelor s-a realizat prin validare încrucișată cu trei segmente (`cv=3`), integrată direct în procesul

de optimizare a hiperparametrilor. Această abordare este preferabilă atunci când dimensiunea datasetului este moderată, deoarece fiecare observație participă atât la antrenare, cât și la validare, reducând variabilitatea estimărilor de performanță.

4.1.3 Algoritmii aleși și justificarea selecției

Au fost antrenați și comparați trei algoritmi cu profile diferite de complexitate:

1. **Random Forest:** A fost ales ca model principal deoarece poate surprinde legături complexe între date fără a necesita pregătiri complicate. Prin combinarea rezultatelor de la mai mulți arbori, algoritmul devine mai stabil și evită memorarea excesivă a datelor de antrenament (overfitting). Un alt avantaj este că indică direct care sunt factorii cu cel mai mare impact asupra adicției.
2. **Regresia Logistică:** Inclusă ca model de referință liniar (*baseline*). Performanța sa oferă un reper util: dacă un model simplu obține rezultate comparabile cu unul complex, complexitatea suplimentară a celui din urmă nu este justificată.
3. **Arborele de Decizie:** Ocupă un loc intermediar, fiind mai expresiv decât regresia logistică, dar mai predispus la supraajustare decât *Random Forest*. A fost inclus pentru a evalua dacă o structură de decizie unică poate concura cu un ansamblu de arbori.

4.1.4 Optimizarea hiperparametrilor prin Grid Search

Toți cei trei algoritmi au fost optimizați prin `GridSearchCV`, testând complet configurațiile din grilele predefinite:

- **Random Forest:** S-a variat numărul de arbori (`n_estimators`: 50 sau 100) și adâncimea maximă (`max_depth`: 5, 10 sau nelimitat).
- **Regresia Logistică:** Parametrul C (controlul regularizării) a fost testat pe valorile 0.1, 1.0 și 10.0. O valoare mică a lui C impune o regularizare mai puternică, penalizând coeficienții mari.
- **Arborele de Decizie:** Grila a combinat adâncimi diferite (3, 5 sau 10) cu două criterii de divizare: *Gini* și *Entropy*.

4.2 Analiza matricei de corelație

Pentru a înțelege relațiile statistice dintre variabilele colectate, a fost generată matricea de corelație (Figura 4.1). Această etapă a permis identificarea factorilor care au cea mai mare influență asupra variabilei țintă `addicted_label`.




Figura 4.1: Matricea de corelație a factorilor comportamentali

Din analiza coeficienților de corelație rezultați, se pot extrage următoarele concluzii:

- **Corelații puternice cu adicția:** Variabilele `daily_screen_time_hours` (0.58) și `weekend_screen_time` (0.56) prezintă cele mai ridicate valori, confirmând faptul că durata totală de utilizare este principalul indicator al dependenței digitale.
- **Impactul rețelelor sociale:** Timpul alocat aplicațiilor de socializare (`social_media_hours`) are o corelație moderată de 0.41, fiind un factor de risc mai important decât jocurile video sau timpul alocat studiului.
- **Independența vârstei:** Valoarea de 0.00 înregistrată în dreptul variabilei `age` sugerează că, în acest set de date, riscul de adicție nu este influențat de vârsta utilizatorului, fiind distribuit uniform.
- **Multicoliniaritatea:** S-a observat o corelație extrem de ridicată (0.96) între timpul total de ecran zilnic și cel din weekend, fapt ce indică o constanță a obiceiurilor de utilizare pe parcursul întregii săptămâni.

Această analiză a validat setul de date și a oferit argumente matematice pentru performanța ridicată a algoritmilor de clasificare implementați ulterior.

Capitolul 5

Testare și validare

Evaluarea modelelor reprezintă etapa critică în care se determină capacitatea algoritmilor de a generaliza informația pe date noi. În acest capitol sunt prezentate metricile alese și compararea performanțelor obținute de cele trei configurații testate.

5.1 Metrici de evaluare utilizate

Pentru a avea o imagine completă asupra calității clasificării, nu s-a utilizat doar acuratețea, ci un set de metrici complementare extrase din raportul de clasificare (*Classification Report*):

- **Acuratețea (Accuracy):** Măsoară procentul total de predicții corecte (atât pentru clasa 0, cât și pentru clasa 1). Deși este un indicator intuitiv, acesta poate fi înșelător dacă clasele sunt dezechilibrate.
- **Precizia (Precision):** Răspunde la întrebarea: „Din toți utilizatorii pe care modelul i-a etichetat ca dependenți (1), câți sunt cu adevărat?”. O precizie ridicată este esențială pentru a evita alarmele false.
- **Sensibilitatea (Recall):** Măsoară capacitatea modelului de a detecta toți utilizatorii cu risc. Un *recall* scăzut ar însemna că mulți utilizatori cu adicție reală sunt trecuți cu vederea (fals negativi), ceea ce este periculos într-un context de sănătate.
- **Scorul F1:** Reprezintă media armonică între precizie și sensibilitate, fiind cea mai robustă metrică atunci când se dorește un echilibru între evitarea alarmelor false și detectarea tuturor cazurilor de risc.

5.2 Analiza comparativă a algoritmilor

În urma rulării procesului de optimizare prin *GridSearchCV* și a testării pe setul de date de control (20% din eșantion), s-au obținut următoarele rezultate:

COMPARARE REZULTATE FINALE		
	Model	Acuratete
2	Decision Tree	0.939333
0	Random Forest	0.926667
1	Logistic Regression	0.877333

Figura 5.1: Compararea rezultatelor finale pentru algoritmi testati

5.2.1 Interpretarea rezultatelor

În urma testării, modelul Decision Tree a demonstrat cea mai ridicată performanță, atingând o acuratețe de 93,93%. Acest rezultat sugerează că setul de date prezintă structuri de decizie bine definite, pe care un singur arbore optimizat le poate capta cu o precizie ridicată. Modelul Random Forest a urmat îndeaproape cu 92,66%, oferind o stabilitate similară, dar fără a aduce un câștig suplimentar de acuratețe în acest caz specific. Deși Random Forest este teoretic mai puternic, pe acest set de date specific, un singur arbore a reușit să găsească regulile optime de split fără a introduce zgomotul suplimentar care apare uneori în modelele de ansamblu mai mari.

Regresia Logistică, deși a oferit o acuratețe solidă de 87,73%, a fost limitată de natura sa liniară. Aceasta nu a reușit să egaleze modelele bazate pe arbori în cazurile complexe de intersecție a factorilor (de exemplu, situații în care un timp redus pe social media este compensat de o frecvență critică a notificărilor sau de un nivel extrem de stres). În urma analizei comparative, algoritmul **Decision Tree** a fost selectat ca model final pentru sistemul de predicție.

5.2.2 Unde greșește modelul?

Analizând raportul detaliat, se observă că majoritatea erorilor de clasificare apar în zona utilizatorilor cu adicție „Mild” (ușoară). Deoarece aceștia prezintă trăsături comportamentale foarte apropiate de utilizatorii echilibrați (clasa 0), modelul tinde uneori să îi clasifice eronat ca fiind fără risc.

Totuși, pentru cazurile de adicție moderată și severă, modelele bazate pe arbori (Decision Tree și Random Forest) au prezentat o sensibilitate de aproape 100%. Acest lucru confirmă utilitatea practică a sistemului: acesta excelează exact acolo unde intervenția este cea mai urgentă, identificând cu succes utilizatorii care au depășit pragul critic al utilizării problematice a smartphone-ului.

Capitolul 6

Rezultate și Discuții

În această etapă, se evaluează nu doar cât de precis este modelul, ci și modul în care acesta ia deciziile, asigurând transparența algoritmului.

6.1 Performanța modelului final

Conform rezultatelor obținute în urma testării (Figura 5.1), modelul bazat pe **Decision Tree** a înregistrat cea mai ridicată acuratețe, de **93.93%**. Această valoare demonstrează o capacitate excelentă de a distinge între utilizatorii cu comportament normal și cei expuși riscului de adicție. Modelul **Random Forest** a oferit o performanță similară (**92.66%**), confirmând robustețea metodelor bazate pe arbori pentru acest set de date.

6.2 Analiza erorilor

În ciuda acurateței ridicate, o analiză a matricii de confuzie indică faptul că erorile apar cu precădere în zona de *false negative*.

- **Ambiguitatea clasei Mild:** Majoritatea erorilor se produc la utilizatorii cu nivel de adicție scăzut. Aceștia au valori ale predictorilor (ex: timp de ecran) foarte apropiate de media utilizatorilor din clasa 0.
- **Zgomotul datelor:** Comportamentele atipice, cum ar fi utilizatorii care au un timp de ecran ridicat exclusiv pentru scopuri educaționale (fără a fi dependenți), pot induce modelul în eroare, acesta clasificându-i eronat ca fiind în clasa 1.

6.3 Explicabilitatea modelului

Pentru a înțelege logica din spatele fiecărei clasificări, am recurs la tehnici de explicabilitate care transformă modelul dintr-o „cutie neagră” într-un sistem transparent. Analizând importanța atributelor în cadrul modelului Decision Tree, am putut observa exact care sunt factorii de risc cu cel mai mare impact în diagnosticarea utilizatorilor.




Figura 6.1: Impactul timpului pe Social Media asupra nivelului de adicție

Analiza arată următoarele aspecte critice:

1. **Timpul pe Social Media:** Așa cum se observă în Figura 6.1, există o creștere liniară și directă între orele petrecute pe rețelele sociale și severitatea adicției. Aceasta este variabila cu cea mai mare pondere în decizia algoritmului.
2. **Weekend vs. Daily:** Modelul acordă o importanță sporită timpului petrecut pe dispozitiv în weekend. Această observație sugerează că lipsa unei structuri (muncă/scoală) favorizează comportamentele compulsive.
3. **Interacțiunea factorilor:** Algoritmul nu decide pe baza unei singure variabile. De exemplu, un număr mare de deschideri de aplicații (*app opens*), corelat cu un somn redus, declanșează imediat clasificarea în clasa 1, confirmând capacitatea modelului de a înțelege contextul utilizatorului.

Capitolul 7

Concluzii și direcții viitoare

Proiectul a demonstrat modul în care algoritmi de învățare automată pot fi utilizați pentru a identifica riscul de adicție digitală. Rezultatele obținute confirmă faptul că monitorizarea tiparelor de utilizare zilnică a smartphone-ului reprezintă o metodă eficientă de prevenție.

7.1 Cunoștințe extrase din proiect

Pe parcursul elaborării lucrării, au fost evidențiate următoarele aspecte:

- **Importanța pregătirii datelor:** Succesul programului depinde în mare măsură de rigoarea etapelor de curățare și pre-procesare a datelor brute.
- **Transparența decizională:** S-a demonstrat că nu este suficient ca un model să aibă o acuratețe ridicată; este esențial să poată fi explicată logica din spatele fiecărei decizii (de exemplu, impactul orelor petrecute pe rețelele sociale).
- **Utilitatea tehnologiei:** S-a confirmat faptul că algoritmi pot servi drept sprijin real pentru sănătatea utilizatorilor, oferind o bază matematică pentru evaluarea comportamentului.

7.2 Limitările abordării

Deși sistemul a atins o acuratețe de 93.93%, au fost identificate câteva puncte slabe:

- **Lipsa contextului:** Algoritmul nu poate diferenția dacă timpul petrecut pe telefon este alocat muncii, educației sau divertismentului, tratând toate activitățile în mod egal.
- **Caracterul static:** Analiza se bazează pe cifre dintr-un moment fix în timp, fără a surprinde schimbările comportamentale care pot apărea de la o săptămână la alta.
- **Eșantionul de date:** Modelele au fost antrenate pe un set de date specific, fiind necesară o testare pe categorii mai diverse de persoane pentru o generalizare completă.

7.3 Îmbunătățiri și direcții viitoare

Pentru dezvoltarea ulterioară a proiectului, sunt în vedere următoarele direcții:

- **Dezvoltarea unei aplicații mobile:** Integrarea codului într-o soluție software care să emită notificări de avertizare în timp real atunci când riscul de adicție devine ridicat.
- **Analiza dinamică:** Monitorizarea continuă a utilizării pe parcursul întregii zile pentru a oferi recomandări personalizate de pauze.

7.4 Utilizarea modelului în psihologia comportamentală

Alegerea unui Arbore de Decizie oferă avantaje clare în psihologie și în studiul sănătății mentale, deoarece transformă un cod matematic într-un instrument ușor de înțeles de către specialiști:

- **Explicații simple și clare:** Spre deosebire de alte modele greu de interpretat, Arborele de Decizie funcționează ca o schemă logică vizuală. Un psiholog poate vedea și explica exact regulile aplicate (de exemplu: *„Dacă timpul pe Social Media depășește 3.5 ore și somnul este sub 6 ore, riscul de adicție este maxim”*). Acest lucru ajută la explicarea problemei direct în fața pacientului.
- **Găsirea punctelor critice:** Modelul arată exact care sunt obiceiurile care fac cel mai rău. În acest caz, timpul pierdut pe rețelele sociale și utilizarea telefonului în weekend au cel mai mare impact. Psihologii pot folosi aceste informații pentru a le cere pacienților reguli clare, cum ar fi oprirea notificărilor sau reducerea ecranului în zilele libere.
- **Depistare timpurie (Screening):** Datorită preciziei de 93.93%, programul poate fi folosit pentru teste rapide în școli sau licee. Acesta poate identifica elevii care se află la începutul dependenței (nivelul Mild sau Moderate), permițând consilierilor școlari să intervină înainte ca problemele de somn sau stresul să devină grave.

Bibliografie

- [1] M. Kwon, et al., *The Smartphone Addiction Scale: A Shortened Form and Psychometric Characteristics of the SAS-SV*, PLoS ONE, 2013.
- [2] K. Demirci, et al., *Relationship of smartphone use severity with sleep quality, depression, and anxiety in university students*, Journal of Behavioral Addictions, 2015.
- [3] M. A. Christensen, et al., *Direct Measurements of Smartphone Screen Time: Relationships with Demographics and Sleep*, PLOS ONE, 2016.
- [4] L. Hale și S. Guan, *Screen time and sleep among school-aged children and adolescents: A systematic literature review*, Sleep Medicine Reviews, 2015.
- [5] M. Samaha și N. S. Hawi, *Relationships among smartphone addiction, stress, academic performance, and satisfaction with life*, Computers in Human Behavior, 2016.
- [6] S. Gokcearslan, et al., *Modelling smartphone addiction: The role of self-regulation, general self-efficacy and cyberloafing*, Computers in Human Behavior, 2016.
- [7] Y. H. Lin, et al., *Development of an app-based smartphone addiction scale as a screening tool*, Journal of Therapeutic Health, 2015.
- [8] A. K. Przybylski, et al., *Motivational, emotional, and behavioral correlates of fear of missing out*, Computers in Human Behavior, 2013.
- [9] C. Yildirim și A. P. Correia, *Exploring the dimensions of nomophobia: Development and validation of a self-reported questionnaire*, Computers in Human Behavior, 2015.
- [10] A. Tandon, et al., *Dark side of social media: Explaining the antecedents of social media discontinuance intentions*, Journal of Retailing and Consumer Services, 2020.